APRENDIZADO NÃO-SUPERVISIONADO

K-Means: Descobrindo Padrões Ocultos na Indústria



Prof. André Felipe Savedra Cruz

A Fábrica Cega

Temos centenas de máquinas gerando dados de sensores (Temperatura, RPM, Torque) ininterruptamente.

Problema: Não temos histórico de quais máquinas quebraram no passado. Não há rótulos ou "respostas" prévias nos dados.

Objetivo: Agrupar automaticamente as máquinas em "Perfis de Operação" (ex: Normal, Sobrecarga, Ociosa) analisando apenas as similaridades no comportamento dos sensores.



Mudança de Paradigma



Sem "Gabarito"

Diferente do k-NN e do Naive Bayes, aqui não existe a fase de "ensinar a IA com a resposta correta". Não há dados rotulados.



Matemática Cega

O algoritmo entra "cego" nos dados e usa matemática geométrica pura para encontrar semelhanças, estruturas e agrupamentos naturais.



Principais Usos

Segmentação de clientes por perfil, detecção de anomalias operacionais (outliers) e compressão técnica de dados.

Prof. André Felipe Savedra Cruz

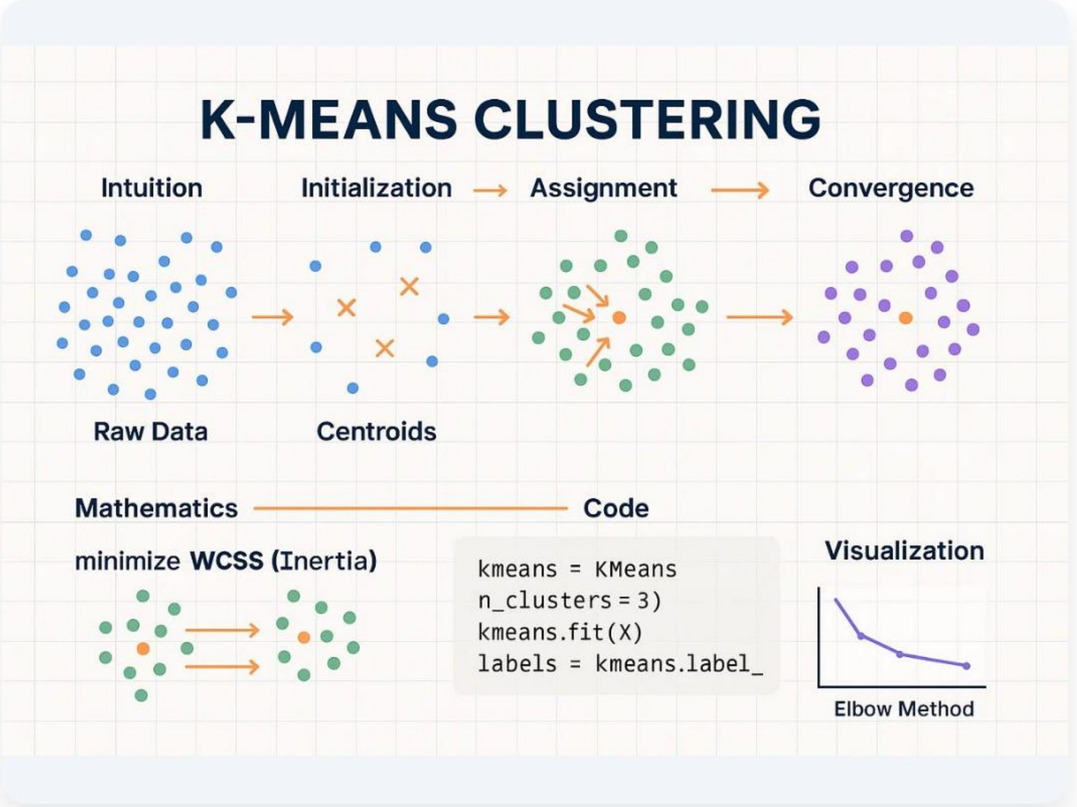
O Algoritmo K-Means

"K" refere-se ao número de grupos (clusters) que queremos encontrar no conjunto de dados.

"Means" (Médias) refere-se ao ponto central matemático (centroide) de cada grupo.

Passo a Passo:

1. Define-se o número **K** desejado.
2. O algoritmo distribui K centroides aleatoriamente pelo mapa.
3. Cada dado se liga ao centroide mais próximo dele.
4. O centroide se reposiciona no meio geométrico exato do seu novo grupo. O ciclo se repete até estabilizar (parar de mover).



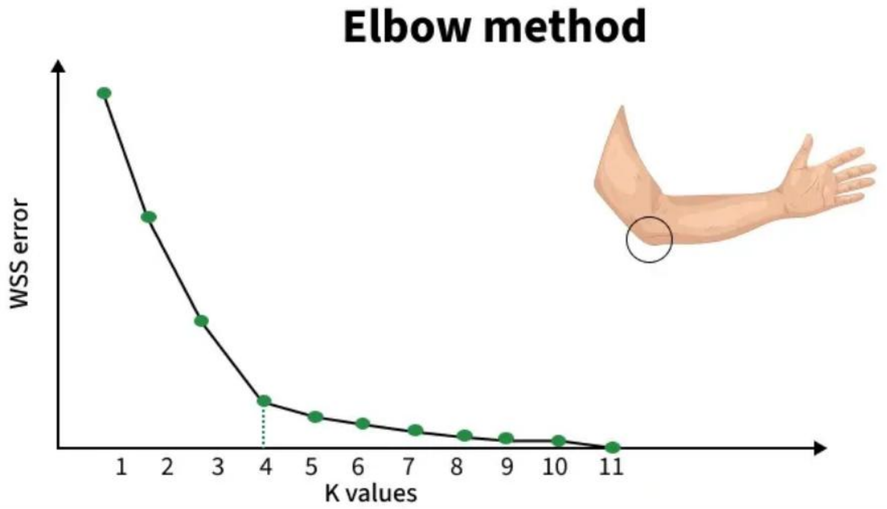
Prof. André Felipe Savedra Cruz

O Método do Cotovelo (Elbow Method)

Se não temos as respostas de antemão, como saber se a fábrica tem 2, 3, ou 10 perfis de operação diferentes?

Calculamos o algoritmo K-Means repetidas vezes para vários valores diferentes de K (ex: de 1 a 10 grupos).

Medimos a **Inércia** (o erro interno ou dispersão dos grupos). Onde o gráfico apresenta uma quebra brusca de tendência (formando um "cotovelo"), geralmente encontramos o número ótimo de grupos para aquela realidade.



Dados Reais de Manutenção Preditiva

Utilizaremos o famoso **Predictive Maintenance Dataset (AI4I 2020)** disponibilizado pela Universidade da Califórnia (UCI).

Abaixo estão os sensores que a inteligência artificial irá analisar para criar os agrupamentos (clusters):

- **Temperatura do Ar (K):** Condição ambiental ao redor da máquina.
- **Temperatura do Processo (K):** Aquecimento gerado pela operação.
- **Velocidade de Rotação (RPM):** Rotações por minuto do eixo principal.
- **Torque (Nm):** Força de torção aplicada pela máquina.
- **Desgaste da Ferramenta (min):** Tempo total de uso contínuo da broca/ferramenta.

Prof. André Felipe Savedra Cruz

Preparação dos Dados

⚠ O Problema das Grandezas

O K-Means é um algoritmo essencialmente geométrico. Ele calcula a **distância física** entre os pontos de dados.

Se a velocidade do RPM for "2000" e o Torque for "40", o valor gigantesco do RPM vai "esmagar" a influência do torque no cálculo de distância, causando um viés imenso na IA.

⚖ A Solução: StandardScaler

Antes de aplicar o agrupamento, é absolutamente obrigatório nivelar o campo de jogo.

O método `StandardScaler()` processa a matriz e coloca todas as variáveis (RPM, Torque, Temperatura) na **mesma proporção matemática**, mantendo as características do dado intactas, mas em uma escala justa.

Métrica de Silhueta (Silhouette Score)

📏 Medindo a Qualidade

Como avaliar se um agrupamento (cluster) ficou estatisticamente bom se não temos as respostas reais para comparar (Acurácia não existe aqui)?

O **Silhouette Score** avalia duas coisas: o quão coeso (apertado) é um grupo internamente e o quão distante (separado) ele está dos outros grupos vizinhos.

Interpretando os Valores

- A métrica varia rigorosamente de **-1 a 1**.
- **Valor Próximo a 1:** Grupos perfeitamente densos e bem separados da vizinhança. Cenário ideal.
- **Valor Próximo a 0:** Grupos estão se sobrepondo, limites confusos.
- Na indústria de dados complexos, valores **acima de 0.5** já indicam uma separação estrutural muito aceitável e útil.

Prof. André Felipe Savedra Cruz

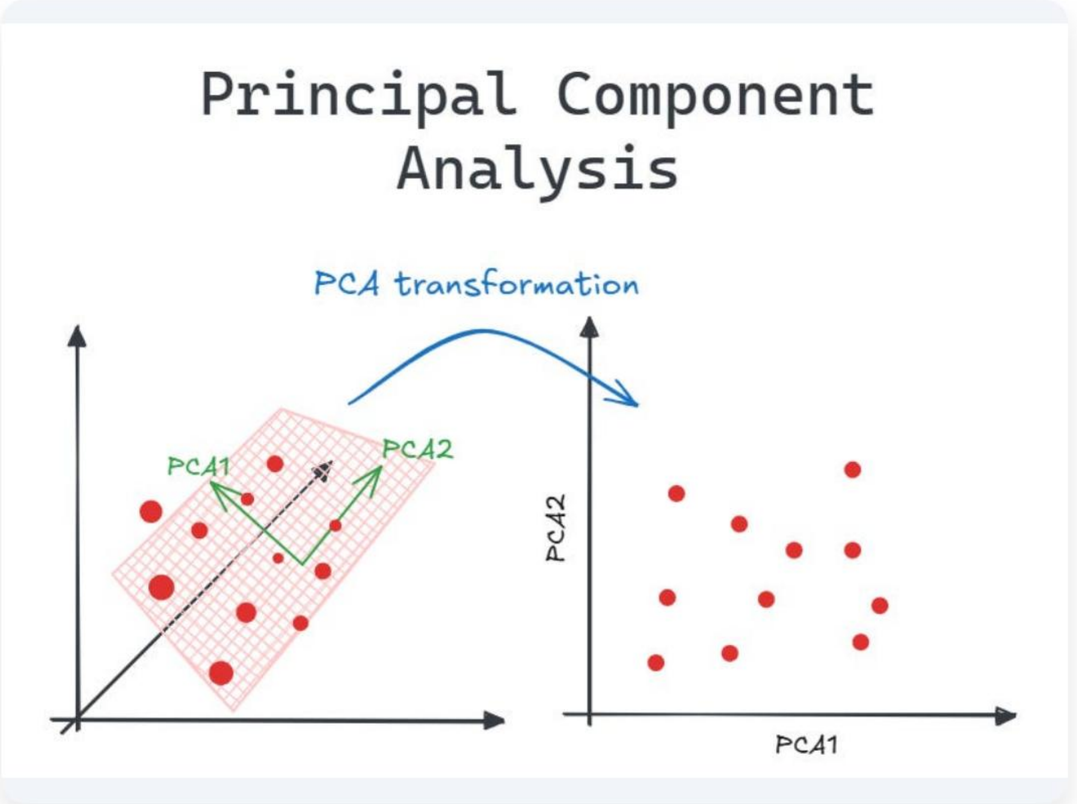
Redução de Dimensionalidade (PCA)

Nossos dados reais possuem 5 colunas (os 5 sensores mencionados anteriormente).

Isso significa que a matemática do agrupamento está ocorrendo em um hiper-espaço de **5 dimensões** simultâneas!

Como humanos só enxergam em até 3 dimensões, usaremos o **PCA (Análise de Componentes Principais)** na nossa prática.

O PCA vai extrair as informações principais e "projetar uma sombra" bidimensional (2D) dos nossos dados, nos permitindo desenhar os agrupamentos da fábrica em um gráfico simples com eixo X e eixo Y.



Mão na Massa

Prática no Google Colab

Acessem o link do notebook disponibilizado na plataforma.

O dataset será puxado automaticamente via GitHub da universidade. Executem as células de código para plotar o método do cotovelo, descobrir o número ótimo de perfis da fábrica e criar os clusters!

Abrir Google Colab →

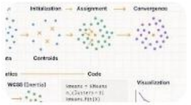
Prof. André Felipe Savedra Cruz

Image Sources



https://www.valleyintlsupply.com/feed/rfid-sensor-technology/hero-ce7087d3fb.jpg

Source: www.valleyintlsupply.com



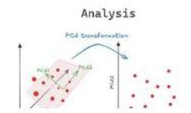
https://miro.medium.com/v2/resize:fit:1200/1*igBfOi1IFWA_H3aNZG0bzQ.png

Source: ai.plainenglish.io



https://media.geeksforgeeks.org/wp-content/uploads/20251111115104211390/elbow_method.webp

Source: www.geeksforgeeks.org



https://substackcdn.com/image/fetch/$s_!_xRi!,f_auto,q_auto:good,fl_progressive:steep/https%3A%2F%2Fsubstack-post-media.s3.amazonaws.com%2Fpublic%2Fimages%2Fa00f3301-9f4f-4de3-a5bb-dc8866c1afc4_819x580.png

Source: mlpills.substack.com